



重庆大学
CHONGQING UNIVERSITY

研究生课程考查

科 目: 现代数字信号处理 教 师: _____

姓 名: ***** 学 号: _____

专 业: 电子信息 类 别: 专业

上课时间: 2025 年 10 月 至 2025 年 12 月

考 生 成 绩:

平时成绩	卷面成绩	课程综合成绩

阅卷评语: _____

阅卷教师 (签名)_____

重庆大学研究生院制

基于智能手机 IMU 数据的卡尔曼滤波姿态估计算法设计与实现

****学院 *****

中文摘要：本文针对智能手机中微机电系统（MEMS）惯性测量单元（IMU）数据的姿态估计问题，设计并实现了一种基于卡尔曼滤波的算法。论文首先分析了加速度计和陀螺仪的互补特性：加速度计在低频段提供无漂移的绝对角度参考但易受高频噪声影响，陀螺仪在高频段响应灵敏但存在积分漂移。在此基础上，构建了离散时间线性卡尔曼滤波器，将俯仰角和陀螺仪零偏作为状态向量，通过“预测-校正”流程融合多源传感器数据。实验采用智能手机采集 IMU 数据（采样频率 50Hz），并通过 Python 程序实现算法。结果表明，卡尔曼滤波能有效抑制加速度计的高频噪声，同时修正陀螺仪的零偏漂移，在动态环境中实现平滑且稳定的姿态跟踪。本研究验证了卡尔曼滤波在消费级 MEMS 传感器环境中的鲁棒性，为低成本姿态估计系统提供了实用解决方案。

关键词：卡尔曼滤波；姿态估计；IMU；传感器融合；智能手机

1 绪论

1.1 研究背景与意义

随着物联网 (IoT)、无人系统 (Unmanned Systems) 以及虚拟现实 (VR/AR) 技术的飞速发展, 载体的姿态估计 (Attitude Estimation) 已成为自动控制与人机交互领域的核心技术之一^[1]。无论是在四旋翼无人机的飞行稳定控制^[2]、自动驾驶汽车的定位导航^[3], 还是在智能手机的体感游戏中, 实时、精准地获取载体的俯仰角 (Pitch) 和横滚角 (Roll) 都是系统正常运行的前提条件。

在传统的惯性导航系统中, 通常采用高精度的光纤陀螺仪或激光陀螺仪, 但其昂贵的造价和巨大的体积限制了其在消费级电子产品中的应用。近年来, 微机电系统 (MEMS) 技术的成熟使得低成本、微型化的惯性测量单元 (Inertial Measurement Unit, IMU) 得以普及^[4]。目前, 几乎所有的智能手机都集成了包含三轴加速度计和三轴陀螺仪的六轴 IMU 芯片。然而, 受限于制造工艺和成本, 消费级 MEMS 传感器的测量精度相对较低, 存在显著的随机噪声、零偏不稳定性 (Bias Instability) 以及温度漂移等问题^[5]。

因此, 如何利用低精度的 MEMS 传感器数据, 通过先进的数字信号处理算法提取出高精度的姿态信息, 是一个极具工程应用价值且充满理论挑战的研究课题^[6]。这不仅是解决低成本导航问题的关键, 也是对现代数字信号处理理论中“信号估计”与“噪声抑制”思想的最佳实践。

1.2 问题描述与传感器特性分析

本报告旨在解决的核心问题是: 在存在显著传感器噪声和动态干扰的环境下, 如何融合多源传感器数据, 获得最优的姿态角度估计。

在姿态解算中, 单一传感器往往存在无法克服的物理局限性:

(1) 加速度计 (Accelerometer): 通过测量重力加速度分量来计算倾角。在静态或准静态条件下, 其具有较好的长期稳定性, 不存在漂移。然而, 加速度计测量的是“比力” (Specific Force), 即重力与运动加速度的矢量和。当载体处于剧烈运动或存在高频振动时, 外部加速度会严重干扰重力分量的提取, 导致计算出的角度包含大量高频噪声, 无法反映真实姿态^[7]。

(2) 陀螺仪 (Gyroscope): 通过测量角速度 (Angular Velocity) 并对时间进行积分来获取角度变化。其具有极高的动态响应特性, 短时间内精度很高。但是, 由于积分运算的特性, 陀螺仪的测量误差 (如白噪声和随机游走) 会随时间累积, 导致计算出的

角度产生严重的“零偏漂移”现象。

显而易见，仅依靠单一传感器无法满足长时间、高动态的姿态估计需求^[8]。这实际上构成了一个典型的多传感器数据融合（Multi-sensor Data Fusion）问题：如何结合加速度计的“低频准确性”和陀螺仪的“高频准确性”，取长补短，构建一个鲁棒的姿态观测系统^[9]。

2 传感器原理与数学模型

本章将详细阐述惯性测量单元（IMU）中加速度计和陀螺仪的工作原理，建立姿态解算的运动学方程，并从信号处理的角度分析传感器的误差特性，为后续卡尔曼滤波算法的设计提供数学依据。

2.1 坐标系定义

在进行姿态解算前，必须明确定义参考坐标系^[10]。本报告采用以下两个坐标系：

1. 导航坐标系 (Navigation Frame, n -系)：选取为地理坐标系（NED 或 ENU），作为绝对静止的参考基准。在本实验的短时测量中，假设地球是平坦且不转动的。其中重力加速度矢量 $\mathbf{g}$ 在该坐标系下恒指向地心（垂直向下）。

2. 载体坐标系 (Body Frame, b -系)：与智能手机固连。定义如下：

(1) X_b 轴：沿手机屏幕向右。

(2) Y_b 轴：沿手机屏幕向上。

(3) Z_b 轴：垂直手机屏幕向外。

3. 载体的姿态角 (Attitude Angles) 定义为 b -系相对于 n -系的旋转角度，即欧拉角：

(1) 横滚角 (Roll, ϕ)：绕 X_b 轴旋转的角度。

(2) 俯仰角 (Pitch, θ)：绕 Y_b 轴旋转的角度。

(注：由于未使用磁力计，本报告不讨论绕 Z 轴旋转的航向角 Yaw)

2.2 加速度计测量模型

2.2.1 测量原理与姿态计算

MEMS 加速度计利用微机械结构的惯性力来测量载体所受的“比力”(Specific Force)。理想情况下^[11]，加速度计的输出 $\mathbf{a}_m$ 包含载体运动加速度 $\mathbf{a}$ 和重力加速度分量 $\mathbf{g}$ ：

$$\mathbf{a}_m = \mathbf{a} - \mathbf{R}_n^b \mathbf{g} \quad (2.1)$$

其中 $\mathbf{R}_n^b$ 是从导航系到载体系的旋转矩阵。

在准静态 (Quasi-static) 假设下，认为载体的运动加速度远小于重力加速度 ($|\mathbf{a}| \ll$

$|g|$)，此时加速度计主要测量重力矢量在载体坐标轴上的投影。根据几何关系，可以推导出利用加速度计观测值 (a_x, a_y, a_z) 计算姿态角的公式：

$$\phi_{acc} = \arctan\left(\frac{a_y}{a_z}\right) \quad (2.2)$$

$$\theta_{acc} = \arctan\left(\frac{-a_x}{\sqrt{a_y^2 + a_z^2}}\right) \quad (2.3)$$

2.2.2 误差分析与信号特性

虽然上述公式在静止时非常准确，但在实际应用中存在以下严重问题：

- (1) 高频噪声干扰：任何非重力的外部加速度（如手部颤动、车辆加减速）都会叠加在测量值上，表现为高幅度的高频噪声。
- (2) 测量模型失效：当载体进行剧烈运动时，准静态假设不再成立，此时计算出的角度完全失真。

从信号统计特性来看，加速度计测量的角度 z_{acc} 可以建模为真实角度 θ_{true} 加上高斯白噪声 v ：

$$z_{acc} = \theta_{true} + v, \quad v \sim N(0, R_{acc}) \quad (2.4)$$

这表明加速度计在大时间尺度上是无偏估计，适合作为观测向量来修正系统的长期姿态。

2.3 陀螺仪测量模型

2.3.1 测量原理与运动学方程

MEMS 陀螺仪测量的是载体围绕各轴旋转的角速度 $\omega = [\omega_x, \omega_y, \omega_z]^T$ 。

姿态角的变化率与角速度之间存在运动学关系^[12]。在小角度或低动态假设下，近似认为角速度即为角度的导数。但在严格的数学推导中，考虑到欧拉角的变化率，关系如下：

$$\begin{bmatrix} \dot{\phi} \\ \dot{\theta} \end{bmatrix} = \begin{bmatrix} 1 & \tan \theta \sin \phi & \tan \theta \cos \phi \\ 0 & \cos \phi & -\sin \phi \end{bmatrix} \begin{bmatrix} \omega_x \\ \omega_y \\ \omega_z \end{bmatrix} \quad (2.5)$$

为简化计算并适应实时系统，通常采用离散时间的积分法更新姿态：

$$\theta_k = \theta_{k-1} + \omega_{y,k} \cdot \Delta t \quad (2.6)$$

$$\phi_k = \phi_{k-1} + (\omega_{x,k} + \omega_{y,k} \sin \phi_{k-1} \tan \theta_{k-1} + \omega_{z,k} \cos \phi_{k-1} \tan \theta_{k-1}) \cdot \Delta t \quad (2.7)$$

2.3.2 零偏漂移与误差模型

陀螺仪的主要误差来源不是高频噪声，而是零偏（Bias）。即使在绝对静止状态下，陀螺仪也会输出一个非零的角速度值。更糟糕的是，这个零偏并不是常数，而是随温度和时间缓慢变化的随机游走过程。

陀螺仪的测量模型通常表示为：

$$\omega_{meas} = \omega_{true} + b + \eta$$

(2.8)

其中：

- ω_{true} ：真实角速度。
- b ：陀螺仪零偏，服从随机游走过程： $\dot{b} = w_b$ 。
- η ：测量白噪声。

如果我们直接对 ω_{meas} 进行积分，常数误 b 会导致角度误差随时间 t 线性增长（漂移），而白噪声 η 积分后会导致角度误差随 $\sqrt{t}$ 发散。

因此，陀螺仪在短时间内（高频段）非常精准，信噪比高，但在长时间内（低频段）不仅不准确，而且误差无界。

2.4 互补特性与融合策略

综上所述，两类传感器具有显著的互补特性：

表 2-1 两类传感器特性对比表			
传感器	信号频域特性	主要误差类型	角色定位
加速度计	低频准确，高频信噪比差	外部加速度干扰（高频）	观测器（Observer）： 提供绝对参考，修正漂移
陀螺仪	高频准确，低频漂移严重	零偏积分累积（低频）	预测器（Predictor）： 提供系统状态的先验估计

这种互补性是设计卡尔曼滤波器的物理基础。我们需要构建一个滤波器，利用陀螺仪进行短时状态预测，同时利用加速度计的观测值不断修正陀螺仪的零偏和姿态角，从而获得全频段的最优估计。

3 卡尔曼滤波算法设计

本章基于第二章建立的物理模型，构建用于姿态估计的离散时间线性卡尔曼滤波器。我们将系统建模为一个随机线性系统，通过“预测-校正”的递归过程，在最小均方误差（MMSE）准则下，实现对载体真实姿态和陀螺仪零偏的最优估计。

3.1 系统状态空间模型建立

建立准确的状态空间模型（State-Space Model）是应用卡尔曼滤波的前提。不同于简单的互补滤波器，我们在状态向量中显式地引入了陀螺仪零偏（Gyroscope Bias），旨在通过滤波过程在线估计并消除该误差，从而抑制积分漂移。

3.1.1 状态向量定义

定义系统在 k 时刻的状态向量 $\mathbf{x}_k$ 为二维列向量，包含当前的俯仰角 θ_k 和陀螺仪在 Y 轴上的零偏 β_k ：

$$\mathbf{x}_k = \begin{bmatrix} \theta_k \\ \beta_k \end{bmatrix} \quad (3.1)$$

其中：

θ_k ：真实俯仰角（单位：rad）。

β_k ：陀螺仪静态漂移量（单位：rad/s）。

3.1.2 状态转移方程 (State Transition Equation)

根据运动学原理，角度的更新依赖于角速度的积分。考虑到陀螺仪测量值 $\omega_{y,k}$ 包含真实角速度、零偏 β 和白噪声，真实角速度可表示为 $(\omega_{y,k} - \beta_{k-1})$ 。

假设采样时间间隔为 Δt ，则角度的离散时间更新方程为：

$$\theta_k = \theta_{k-1} + (\omega_{y,k} - \beta_{k-1})\Delta t \quad (3.2)$$

对于零偏 β_k ，我们将其建模为随机游走过程（Random Walk），即认为在短时间内其值基本不变，但在长时间尺度上受高斯白噪声驱动：

$$\beta_k = \beta_{k-1} \quad (3.3)$$

综合上述两式，可写出线性的状态转移方程矩阵形式：

$$\mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}u_k + \mathbf{w}_{k-1} \quad (3.4)$$

其中：

状态转移矩阵 $\mathbf{A}$ ：

$$\mathbf{A} = \begin{bmatrix} 1 & -\Delta t \\ 0 & 1 \end{bmatrix} \quad (3.5)$$

控制输入矩阵 $\mathbf{B}$ ：

$$\mathbf{B} = \begin{bmatrix} \Delta t \\ 0 \end{bmatrix} \quad (3.6)$$

控制输入变量 u_k ：即当前时刻陀螺仪的测量值 $\omega_{y,k}$ 。

过程噪声 w_{k-1} ：服从高斯分布 $w \sim N(0, Q)$ 。

3.1.3 观测方程 (Measurement Equation)

系统的观测值 z_k 来自于加速度计计算出的俯仰角 θ_{acc} （见第二章公式）。由于加速度计直接测量角度，且我们假设加速度计不包含被建模的偏差（Bias），因此观测方程为：

$$z_k = Hx_k + v_k \quad (3.7)$$

其中：

观测矩阵 H ：用于从状态向量中映射出观测值。

$$H = [1 \quad 0] \quad (3.8)$$

观测噪声 v_k ：代表加速度计的高频振动噪声，服从高斯分布 $v \sim N(0, R)$ 。

3.2 噪声协方差矩阵设计

在卡尔曼滤波中，过程噪声协方差矩阵 Q 和观测噪声协方差矩阵 R 决定了滤波器对“模型预测”与“传感器观测”的信任程度，是影响滤波性能的关键参数。

3.2.1 过程噪声协方差 Q

Q 矩阵反映了系统模型的不确定性以及状态转移过程中的随机干扰。在本系统中，不确定性主要来源于陀螺仪的测量噪声和零偏的随机波动。假设角度噪声方差为 σ_θ^2 ，零偏噪声方差为 σ_β^2 ，则 Q 可设计为：

$$Q = \begin{bmatrix} \sigma_\theta^2 & 0 \\ 0 & \sigma_\beta^2 \end{bmatrix} \approx \begin{bmatrix} 0.001 & 0 \\ 0 & 0.003 \end{bmatrix} \quad (3.9)$$

注： Q 中的参数通常通过经验调试或计算传感器数据的 Allan 方差来确定。

3.2.2 测量噪声协方差 R

R 是一个标量（对于单输入单输出系统），反映了加速度计测量结果的噪声水平。

$$R = E[v_k v_k^T] = \sigma_{acc}^2 \quad (3.10)$$

该值可以通过采集手机静止状态下的加速度计数据，计算其方差来获得。若 R 值设置过大，滤波器将导致响应滞后（Lag）；若 R 值过小，滤波结果将无法有效抑制高频噪声。

3.3 卡尔曼滤波递推算法

基于上述模型，姿态估计的完整流程遵循标准的“预测-校正”五步法。

3.3.1 时间更新（预测阶段）

利用上一时刻的最优估计值和陀螺仪数据，预测当前时刻的状态：

1. 状态先验估计：

$$\mathbf{x}_k^- = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}u_k \quad (3.11)$$

物理意义：利用陀螺仪积分推算当前角度，并假设零偏保持不变。

2. 误差协方差先验估计：

$$\mathbf{P}_k^- = \mathbf{A}\mathbf{P}_{k-1}\mathbf{A}^T + \mathbf{Q} \quad (3.12)$$

物理意义：随着时间的推移，由于积分作用，系统的不确定性（协方差）会逐渐增加。

3.3.2 测量更新（校正阶段）

利用加速度计的观测数据修正先验估计：

3. 计算卡尔曼增益 (Kalman Gain)：

$$\mathbf{K}_k = \mathbf{P}_k^- \mathbf{H}^T (\mathbf{H}\mathbf{P}_k^- \mathbf{H}^T + \mathbf{R})^{-1} \quad (3.13)$$

物理意义： $\mathbf{K}_k$ 是一个权衡因子。当测量噪声 $\mathbf{R}$ 较小时， $\mathbf{K}_k$ 增大，系统更信任观测值；反之则更信任预测值。

4. 状态后验估计（最优估计）：

$$\mathbf{x}_k = \mathbf{x}_k^- + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}\mathbf{x}_k^-) \quad (3.14)$$

物理意义：这是滤波器的输出结果。括号内的项 $(\mathbf{z}_k - \mathbf{H}\widehat{\mathbf{x}}_k^-)$ 被称为新息 (Innovation)，代表了实际观测与模型预测之间的差异。

5. 误差协方差后验更新：

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{H}) \mathbf{P}_k^- \quad (3.15)$$

物理意义：引入观测数据后，系统的不确定性下降，协方差矩阵收敛。

3.4 算法小结

通过上述迭代过程，滤波器能够在每一时刻输出修正后的角度 θ_k 以及估算出的零偏 β_k 。随着时间的推移， β_k 会收敛至陀螺仪真实的漂移值，从而使得即便在没有加速度计数据（如完全失重瞬间）的情况下，依靠修正后的陀螺仪模型也能在短时间内保持较高的姿态解算精度。

4 实验系统与程序实现

本次实验采用手机收集数据，并保存在 CSV 文件内。然后通过 Python 程序处理，并将结果绘制成图像。

数据采集设备为 Redmi Note 12T Pro 智能手机，采用的数据采集软件为 PhyPhox。

采集数据时，实验者将手机握在手中并进行各种旋转，使得手机有各种姿态变化。

采集的数据包含手机的加速度计和陀螺仪的原始数据，采用 CSV 文件格式保存，加速度计和陀螺仪的数据格式分别为 Time, Ax, Ay, Az 和 Time, Gx, Gy, Gz。数据采集频率设置为 50Hz。

数据处理程序采用 Python 3.12 实现，具体代码请参考附录。

5 结果分析与讨论

5.1 整体姿态估计结果分析

图 5-1 给出了完整实验过程中横滚角（Roll）和俯仰角（Pitch）的估计结果。其中，灰色曲线表示仅由加速度计直接解算得到的姿态角，蓝色和红色曲线分别表示经过卡尔曼滤波后的横滚角和俯仰角估计结果。

从整体趋势来看，在实验开始阶段（约 0–15 s），手机处于静止状态。此时，加速度计测量值主要由重力加速度构成，外部加速度干扰较小，因此直接由加速度计解算得到的姿态角较为稳定，曲线几乎呈水平直线。卡尔曼滤波输出与加速度计结果高度一致，说明在静态条件下，滤波器能够正确收敛，不会引入额外的系统偏差。




图 5-1 完整实验数据（0–70 s）

随着实验的进行，手机被人为握持并进行多方向旋转，载体进入明显的动态状态。此时可以观察到，仅依赖加速度计解算的姿态角曲线出现了显著的高频抖动和尖峰波动。这是由于加速度计测量的是比力，当存在较大的线加速度或快速姿态变化时，外部加速度分量会严重干扰重力分量的提取，从而导致姿态角估计结果中混入大量高频噪声。

相比之下，卡尔曼滤波后的姿态估计曲线整体更加平滑，能够有效抑制高频抖动，同时仍然保持对真实姿态变化趋势的良好跟踪能力。在横滚角和俯仰角两个通道中均可观察到这一现象，说明所设计的滤波器在不同姿态轴上的性能具有一致性和稳定性。

此外，在较长时间尺度内，滤波结果未出现明显的发散或漂移，表明通过在状态向量中引入陀螺仪零偏并进行在线估计，卡尔曼滤波器成功抑制了陀螺仪积分误差的累积效应，实现了对姿态角的长期稳定估计。

5.2 局部放大结果与动态性能分析

为了更加清晰地比较滤波前后姿态估计结果在动态过程中的差异，图 5-2 对图 5-1 中 20 s 至 40 s 区间的数据进行了截取和放大显示。该时间段内手机经历了多次较为剧烈的姿态变化，具有较强的代表性。




图 5-2 实验 20 - 40 s 局部放大对比

从图中可以明显看出，在该时间区间内，仅由加速度计解算得到的姿态角曲线存在以下问题：

- (1) 高频噪声显著：灰色曲线在短时间内出现大量快速振荡，即使在真实姿态变化相对平缓的区间，仍然存在明显抖动，降低了姿态估计的可用性。
- (2) 瞬时尖峰误差：在快速转动或加减速过程中，加速度计姿态解算结果会出现幅值较大的瞬时突变，这些突变并不完全反映真实姿态变化，而是由外部加速度干扰所引起。

相比之下，卡尔曼滤波后的姿态估计结果表现出明显优势：

滤波曲线在整体趋势上与加速度计结果保持一致，能够准确反映姿态变化的方向和幅度；

- (1) 高频噪声被显著削弱，曲线连续性和平滑性大幅提升；
- (2) 在姿态快速变化时，滤波结果不存在明显的延迟或滞后，说明滤波器在“平滑性”和“动态响应速度”之间取得了良好的平衡。
- (3) 值得注意的是，滤波后的曲线并非简单的低通滤波结果。在部分姿态快速变化的区间，卡尔曼滤波输出仍然能够保持较陡的变化斜率，体现了陀螺仪在高频段提供的有效动态信息。这正是卡尔曼滤波相较于传统低通滤波方法的核心优势之一。

6 结论

综合整体结果和局部放大分析，可以得出以下结论：

- (1) 卡尔曼滤波显著提高了姿态估计的信噪比

通过融合陀螺仪和加速度计数据，滤波器有效抑制了加速度计在动态条件下引入的高频噪声，使得姿态估计结果更加平滑、稳定。

- (2) 滤波器成功利用了两类传感器的互补特性

实验结果直观地验证了第二章中关于传感器互补特性的理论分析：陀螺仪提供了高频、连续的姿态变化信息，而加速度计为系统提供了长期稳定的绝对参考，二者在卡尔曼滤波框架下实现了最优融合。

- (3) 引入陀螺仪零偏状态具有实际意义

从长时间实验结果来看，滤波输出未出现明显漂移，说明滤波器能够在运行过程中逐步估计并修正陀螺仪零偏，提高了系统的长期稳定性。

- (4) 算法适用于消费级 MEMS 传感器环境

实验采用的手机 IMU 具有噪声大、精度低的典型特征，而卡尔曼滤波仍然能够取得良好的姿态估计效果，表明该算法在实际工程应用中具有较强的鲁棒性和推广价值。

参考文献

- [1] 徐鑫, 赵鹤鸣. 基于改进型卡尔曼滤波的运动载体姿态估计[J]. 传感技术学报, 2020, 33(9): 1279-1284.
- [2] 柏植, 许海峰, 郭凯, 等. 基于自适应扩展卡尔曼滤波算法的无人机姿态估计[J]. 黑龙江工业学院学报(综合版), 2021, 21(9): 54-60.
- [3] 许立松, 马国梁, 闻泉, 等. 基于无迹卡尔曼滤波的火箭弹姿态估计[J]. 弹道学报, 2021, 33(4): 20-25.
- [4] 郝双全. 低成本惯性姿态估计技术研究[D]. 上海交通大学, 2020.
- [5] 段敏, 赵凌, 周莹. 基于扩展卡尔曼滤波的四旋翼无人机姿态估计方法[J]. 现代信息科技, 2022, 6(4): 7-11.
- [6] 刘镇波, 李四海, 王珏, 等. 基于分布式 IMU 的相对姿态估计方法[J]. 弹箭与制导学报, 2014, 34(5): 21-25.
- [7] 马明刚, 严家常, 郑贤喜, 等. 基于 IMU 智能安全帽姿态估计[J]. 工业安全与环保, 2020, 46(3): 34-37.
- [8] 乔美英, 高翼飞, 李宛妮, 等. 基于模糊鲁棒自适应 CKF 算法的 MEMS-IMU 姿态估计[J]. 中国惯性技术学报, 2022, 30(3): 296-303.
- [9] 王子梦. 基于 MEMS 传感器的水下机器人姿态估计研究[D]. 江西理工大学, 2022.
- [10] 郭威, 吴允平, 王廷银. MEMS 四元数卡尔曼滤波算法的电梯姿态估计[J]. 计算机系统应用, 2020, 29(3): 246-252.
- [11] 蒋宗池, 佃松宜, 郭斌, 等. 基于模糊卡尔曼滤波的四旋翼姿态估计方法[J]. 计算机应用与软件, 2023, 40(12): 79-85.
- [12] 王兵权, 孙文强, 解琨阳, 等. 基于调谐卡尔曼滤波的光栅 MOEMS IMU 姿态算法研究[J]. 微纳电子技术, 2025, 62(3): 127-133.

附录

附录 A: Python 程序源代码

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# =====
# 1. 卡尔曼滤波器类定义 (1D Kalman Filter)
# =====
class KalmanFilter1D:
    def __init__(self, Q_angle, Q_bias, R_measure):
        """
        初始化卡尔曼滤波器
        :param Q_angle: 角度的过程噪声协方差 (相信陀螺仪积分的程度)
        :param Q_bias: 零偏的过程噪声协方差 (相信零偏变化的程度)
        :param R_measure: 测量的噪声协方差 (相信加速度计的程度)
        """
        # 过程噪声协方差矩阵 Q
        self.Q_angle = Q_angle
        self.Q_bias = Q_bias
        self.R_measure = R_measure

        # 状态向量 x = [angle, bias]^T
        self.angle = 0.0 # 角度
        self.bias = 0.0 # 陀螺仪零偏

        # 误差协方差矩阵 P (初始化为非零值)
        self.P = np.array([[0.0, 0.0], [0.0, 0.0]])

    def predict(self, rate, dt):
        """
        预测步 (基于陀螺仪)
        :param rate: 陀螺仪角速度 (deg/s 或 rad/s)
        :param dt: 采样时间间隔 (s)
        """
        # 1. 更新状态 (先验估计)
        # angle = angle + (gyro_rate - bias) * dt
        self.angle += (rate - self.bias) * dt

        # 2. 更新误差协方差矩阵 P = F * P * F^T + Q
        # F 是状态转移矩阵: [[1, -dt], [0, 1]]
        self.P[0][0] += dt * (
            dt * self.P[1][1] - self.P[0][1] - self.P[1][0] + self.Q_angle
        )
        self.P[0][1] -= dt * self.P[1][1]
        self.P[1][0] -= dt * self.P[1][1]
        self.P[1][1] += self.Q_bias * dt

        return self.angle

    def update(self, new_angle):
        """
        更新步 (基于加速度计)
```

```

:param new_angle: 加速度计计算出的观测角度
"""
# 1. 计算卡尔曼增益  $K = P * H^T * (H * P * H^T + R)^{-1}$ 
# H 是观测矩阵: [1, 0]
S = self.P[0][0] + self.R_measure # 创新协方差
K0 = self.P[0][0] / S
K1 = self.P[1][0] / S

# 2. 计算新息 (Innovation)  $y = z - H * x$ 
y = new_angle - self.angle

# 3. 更新状态 (后验估计)  $x = x + K * y$ 
self.angle += K0 * y
self.bias += K1 * y

# 4. 更新误差协方差矩阵  $P = (I - K * H) * P$ 
P00_temp = self.P[0][0]
P01_temp = self.P[0][1]

self.P[0][0] -= K0 * P00_temp
self.P[0][1] -= K0 * P01_temp
self.P[1][0] -= K1 * P00_temp
self.P[1][1] -= K1 * P01_temp

return self.angle

# =====
# 2. 工具函数: 从加速度计计算角度
# =====
def calculate_accel_angles(ax, ay, az):
    """
    使用加速度计计算静态倾角
    注意: 这里假设单位一致即可, arctan2 不关心具体是 m/s^2 还是 g
    """
    # Roll (绕 X 轴转动): atan2(Ay, Az)
    roll_acc = np.arctan2(ay, az) * (180.0 / np.pi)

    # Pitch (绕 Y 轴转动): atan2(-Ax, sqrt(Ay^2 + Az^2))
    # 注意: 不同设备的坐标系定义可能不同, 有些是 atan2(Ax, ...)
    pitch_acc = np.arctan2(-ax, np.sqrt(ay**2 + az**2)) * (180.0 / np.pi)

    return roll_acc, pitch_acc

# =====
# 3. 主程序
# =====
def main():
    # --- A. 数据加载 ---
    df = pd.read_csv("data.csv")

    # --- B. 初始化滤波器 ---
    # 参数调优建议:
    # Q_angle: 0.001 (如果你相信陀螺仪积分非常准, 这就设小)

```

```

# Q_bias: 0.003 (允许零偏随时间缓慢变化)
# R_measure: 0.03 (加速度计噪声大, R 要设大一点)
kf_roll = KalmanFilter1D(Q_angle=0.001, Q_bias=0.003, R_measure=0.03)
kf_pitch = KalmanFilter1D(Q_angle=0.001, Q_bias=0.003, R_measure=0.03)

results_roll = []
results_pitch = []

# --- C. 循环处理 ---
# 假设 CSV 中的陀螺仪单位是 rad/s, 加速度计单位是 m/s^2 (或者 g, arctan2 不影响)
# 如果你的陀螺仪数据已经是 deg/s, 请去掉下面的 np.degrees() 转换

for i in range(len(df)):
    # 1. 获取时间间隔 dt
    if i == 0:
        dt = 0.02 # 50Hz 默认
    else:
        dt = df["Time"].iloc[i] - df["Time"].iloc[i - 1]

    # 2. 读取传感器数据
    ax, ay, az = df.iloc[i]["Ax"], df.iloc[i]["Ay"], df.iloc[i]["Az"]
    gx, gy, gz = df.iloc[i]["Gx"], df.iloc[i]["Gy"], df.iloc[i]["Gz"]

    # 转换陀螺仪单位到 deg/s (如果原数据是 rad/s)
    gx_deg = np.degrees(gx)
    gy_deg = np.degrees(gy)

    # 3. 计算加速度计观测角度
    roll_acc, pitch_acc = calculate_accel_angles(ax, ay, az)

    # 4. 卡尔曼滤波步骤
    # Roll 通常对应 Gx (绕 X 轴)
    # Pitch 通常对应 Gy (绕 Y 轴) - 注意正负号取决于安装方向
    kf_roll.predict(rate=gx_deg, dt=dt)
    est_roll = kf_roll.update(new_angle=roll_acc)

    kf_pitch.predict(rate=gy_deg, dt=dt)
    est_pitch = kf_pitch.update(new_angle=pitch_acc)

    results_roll.append(est_roll)
    results_pitch.append(est_pitch)

# --- D. 可视化结果 ---
plt.figure(figsize=(12, 6))

plt.subplot(2, 1, 1)
plt.plot(
    df["Time"],
    calculate_accel_angles(df["Ax"], df["Ay"], df["Az"])[0],
    label="Accel Only (Noisy)",
    color="gray",
    alpha=0.5,
)
plt.plot(
    df["Time"], results_roll, label="Kalman Filtered", color="blue", linewidth=2
)

```



```

plt.title("Roll Estimation")
plt.legend()
plt.grid(True)

plt.subplot(2, 1, 2)
plt.plot(
    df["Time"],
    calculate_accel_angles(df["Ax"], df["Ay"], df["Az"])[1],
    label="Accel Only (Noisy)",
    color="gray",
    alpha=0.5,
)
plt.plot(
    df["Time"], results_pitch, label="Kalman Filtered", color="red", linewidth=2
)
plt.title("Pitch Estimation")
plt.xlabel("Time (s)")
plt.legend()
plt.grid(True)

plt.tight_layout()
plt.show()

if __name__ == "__main__":
    main()

```